

南开大学

信息检索 课程实验报告

HW4 - NKU Web Search Engine



学院 _____ 学院

专业 _____ 专业

姓名 _____ 姓名

学号 _____ 学号

2026 年 5 月 21 日

目录

1	项目背景与目标	3
1.1	与作业要求的对应关系	3
2	系统总体设计	4
3	网页抓取与数据准备	5
4	文本索引设计	7
5	VSM 排序与链接分析	7
6	检索质量优化	8
7	六项查询服务实现	9
7.1	站内查询	9
7.2	文档查询	9
7.3	短语查询	9
7.4	通配查询	10
7.5	查询日志	10
7.6	网页快照	10
8	用户系统、个性化与推荐	13
9	Web 界面与 CLI	15
10	自检结果	16
11	不足与后续改进	17

1 项目背景与目标

本实验依据助教发布的《HW4 - NKU Web Search Engine》要求，面向南开大学校内资源构建 Web 搜索引擎。系统目标包括网页抓取、文本索引、查询服务、个性化查询、Web 界面与个性化推荐。按照原文要求，查询排序以向量空间模型（VSM）为核心，并融合链接分析结果。

本项目选择“综合性 + 附件友好”的南开校内资源搜索主题，覆盖南开新闻网、学校主页、计算机学院、教务、图书馆、学生就业、数学学院和 12 Club 等资源类型。助教鼓励复用成熟包，因此系统新增 Elasticsearch 作为可选查询召回后端，用于候选检索、过滤、短语和通配匹配；最终排序仍在应用层采用 TF-IDF 余弦 VSM、PageRank 和个性化重排。本地倒排索引作为可复现兜底，使未启动 ES 时也能完成演示。



图 1.0.1: 系统首页真实截图

1.1 与作业要求的对应关系

作业要求	本项目实现	状态
网页抓取	礼貌爬虫，遵守 robots.txt，限制访问频率，保存 HTML 快照并解析 PDF/DOC/DOCX/XLS/XLSX 附件。当前真实语料已抓取 132296 条南	完成

	开域名文档，本轮定向新增 32052 条高质量 HTML 页面。	
文本索引	构建 title、url、body、anchor_text、doc_type、attachment_text 等多字段索引，并聚合入链锚文本。	完成
VSM + 链接分析	使用 TF-IDF ltc 加权和余弦相似度作为主排序，融合 PageRank 和时间新鲜度。	完成
六项查询服务	站内查询、文档查询、短语查询、通配查询、查询日志、网页快照全部实现。	完成
个性化查询	注册/登录、角色、兴趣标签、查询历史和点击日志参与排序修正。	完成
个性化推荐	实现搜索联想和结果页相关推荐。	完成

2 系统总体设计

系统分为离线处理和在线服务两部分。离线部分完成抓取、解析、快照保存、本地倒排索引构建、Elasticsearch 批量索引、锚文本聚合和 PageRank 计算；在线部分通过 Flask 提供 Web 页面、用户系统、查询接口、搜索建议、日志和快照查看。搜索时 ES 或本地索引先召回候选，再复用同一套 VSM 排序逻辑重排。

为充分利用成熟工具并满足作业的理论要求，本系统采用两阶段检索架构：检索层（**Retrieval**）默认采用助教鼓励使用的 Elasticsearch 完成倒排索引、分词、多字段 query DSL、短语、通配与过滤召回；同时保留纯 Python 本地倒排索引作为不依赖外部服务的降级路径。排序层（**Ranking**）手实现向量空间模型（VSM），采用 ltc 加权 TF-IDF 与余弦相似度度量内容相关性，并与 PageRank、新鲜度、个性化信号联合产生最终打分。之所以不直接使用 ES 默认 BM25 作为最终排序，是因为 BM25 属概率检索模型，与作业明确要求的 VSM 不符；二阶段架构使系统同时具备 ES 的工程优势与 VSM 的理论合规性。

阶段	核心模块	输出
离线抓取	crawler.py / parser.py / snapshot.py	南开 HTML、附件文本、网页 快照
离线索引	indexer.py / pagerank.py / elasticsearch_backend.py	本地倒排索引、PageRank、可 选 ES 索引
在线检索	search.py / query.py	候选召回、VSM 重排、摘要 和推荐
Web 服务	web.py / SQLite / templates	搜索页面、登录、日志、快 照、下载

图 2.0.1: 系统架构与数据流

核心目录结构如下：

1	代码/	Plain Text
2	├─ nku_search/	
3	├─ crawler.py	礼貌爬虫与附件抓取
4	├─ parser.py	HTML/PDF/DOCX/XLSX 解析
5	├─ indexer.py	多字段索引和 IDF 统计
6	├─ elasticsearch_backend.py	ES 召回与批量索引
7	├─ search.py	ES/本地召回 + VSM 重排
8	├─ database.py	用户、查询日志、点击日志
9	├─ web.py	Flask Web 应用
10	└─ selfcheck.py	自动验收脚本
11	├─ templates/	页面模板
12	├─ static/	样式和前端脚本
13	└─ data/	文档、索引、快照、附件

3 网页抓取与数据准备

爬虫模块限定深入 *.nankai.edu.cn，使用 RobotFileParser 检查 robots.txt，通过 delay 参数限制同一主机的请求间隔，并设置课程作业专用 User-Agent。HTML 页面被解析出标题、正文、链接和锚文本；HTML 原文以 gzip 形式存入 data/snapshots/，作为网页快照来源。

附件抓取根据 URL 后缀或 Content-Type 判断类型，支持 PDF、DOC、DOCX、XLS、XLSX。PDF 使用 pypdf 提取文本，DOCX 使用 python-docx，XLSX 使用 openpyxl。解析后的附件文本与普通网页一起进入统一索引，从而支持文档查询。




图 3.0.2: 抓取主机分布证据

当前真实抓取结果已经达到并超过助教要求的 10 万级规模。data/documents.jsonl 中共有 132296 条唯一文档，全部 URL 均位于南开域名内，涉及 356 个主机；其中 HTML 124844 条、PDF 3902 条、DOCX 1417 条、DOC 1411 条、XLSX 547 条、XLS 175 条。HTML 快照共 124844 份，附件或附件 URL 共 7452 条，索引文件 data/search_index.json 约 1.98 GB。本轮按用户要求完成定向补爬，新增 32052 条高质量 HTML 页面，frontier 继续扩展到 384801 条候选 URL，优先覆盖教务、招生、就业、图书馆、学院和科研相关站点。

为避免项目目录移动后旧绝对路径失效，读取文档元数据时会自动将 data/snapshots/ 和 data/attachments/ 下的历史路径重定位到当前代码目录。这样 documents.jsonl 与 search_index.json 即使在不同机器或不同课程目录中复制，网页快照和附件下载仍然能够正常打开。

大规模抓取不再只追求“再多几万条”，而是先做定向 frontier 预检。预检会合并核心站点种子、过滤 CAS/登录/跳转噪声 URL，并按主机配额重排队列，避免新增 3 万条集中来自单一 WebPlus 站点。本轮实际补爬时关闭附件下载，只抓取 HTML 正文页，避免 _upload 附件队列吞噬爬取预算：

```
1 cd 代码
2 pixi run targeted-crawl -- --dry-run
3 pixi run targeted-crawl -- --target-new 30000
4 pixi run build-index
5 pixi run build-es-index
```

PowerShell

若需要继续维护语料，可在当前 132296 条基础上再次执行定向预检与增量抓取；若只需复现本轮流程，可执行：

```
1 .\.\pixi\envs\default\python.exe .\scripts\crawl_to_100k.py
2 .\.\pixi\envs\default\python.exe -m nku_search.cli build-index
```

4 文本索引设计

索引字段包括：

- **title**: 网页标题，权重最高；
- **body**: 清洗后的网页正文；
- **anchor_text**: 指向当前页面的入链锚文本；
- **url** 与 **host**: 用于站内过滤和展示；
- **doc_type**: 区分 html、pdf、docx、xlsx；
- **snapshot_path**: 快照文件位置；
- **pagerank** 与 **inlinks_count**: 链接分析特征。

中文分词采用 `jieba.lcut_for_search`，并加入南开、南开大学、八里台、津南、伯苓班、信息检索、向量空间模型、PageRank、计网、计算机网络等自定义词。索引构建阶段统计每个词的 **df**，保存平滑 **IDF**：

$$\text{idf}_t = \log \frac{N + 1}{\text{df}_t + 1} + 1 \quad (4.1)$$

在线服务可选择两种召回路径。本地路径直接使用 **term_docs** 倒排候选；Elasticsearch 路径将 **title**、**body**、**anchor_text**、**url**、**host**、**doc_type**、**snapshot_path**、**pagerank** 等字段批量写入 ES，通过 **multi_match**、**match_phrase**、通配和过滤 DSL 召回 **top-K**，再交给同一 **VSM** 函数重排。这样利用成熟查询组件降低高级检索复杂度，同时保留作业要求的 **VSM** 主排序可解释性。

5 VSM 排序与链接分析

助教要求明确写出“基于向量空间模型，结合链接分析结果对查询结果排序”。因此本系统主排序采用 **VSM**，而不是把 **BM25** 作为核心模型。对查询和文档字段使用 **ltc** 风格的 **TF-IDF**：

$$w_{t,d} = (1 + \log \text{tf}_{t,d}) \cdot \log \frac{N}{\text{df}_t} \quad (5.2)$$

查询向量与文档字段向量的相似度使用余弦相似度：

$$\text{sim}(q, d_f) = \frac{q \cdot d_f}{\|q\| \|d_f\|} \quad (5.3)$$

多字段融合时，标题、锚文本、正文、附件文本分别设置权重：

$$S_{\text{vsm}(q,d)} = \sum_f w_f \cdot \text{sim}_{f(q,d)} \quad (5.4)$$

链接分析使用 **PageRank**。抓取阶段记录页面出链，离线迭代得到归一化 **PageRank**。最终排序公式为：

$$\text{score}(q, d) = S_{\text{vsm}(q,d)} \cdot \left(1 + \alpha \log\left(1 + \widehat{\text{PR}(d)}\right)\right) + \beta \cdot \text{fresh}(d) + \gamma \cdot \text{pers}(u, d) \quad (5.5)$$

其中默认参数为 $w_{\text{title}} = 4$ 、 $w_{\text{anchor}} = 3$ 、 $w_{\text{attachment}} = 1.5$ 、 $w_{\text{body}} = 1$ 、 $\alpha = 0.5$ 、 $\beta = 0.1$ 、 $\gamma = 0.3$ 。 $\text{fresh}(d)$ 是抓取时间的新鲜度， $\text{pers}(u, d)$ 是登录用户偏好带来的轻量修正。ES 召回返回的候选文档不会直接使用 ES 分数作为最终排名，而是进入上述 **VSM + PageRank** 公式重新打分。新版排序还增加查询意图、精确短语、多词覆盖和标题质量修正信号：例如“就业”“选课”“图书馆”等查询会提升对应主题页面；CAS 登录页、URL 标题页和空正文页被降权；不可读文件名的 PDF 会优先用正文首个有效句子作为展示标题。

排序信号	实现位置	作用
VSM	search.py 中 <code>_vsm_score</code> 、 <code>_field_cosine</code>	TF-IDF 余弦相似度，作为主相关性分数
PageRank	pagerank.py 离线计算，search.py 融合	结合链接分析结果提升权威页面
新鲜度	search.py 中 <code>_freshness_boost</code>	轻量提升较新页面
个性化	database.py + search.py	按角色、兴趣和点击历史微调排序
多样性	search.py 中 <code>_apply_result_diversity</code>	合并重复列表页，限制单 host 霸屏
质量修正	search.py 中 <code>_is_low_quality_page</code> 、 <code>_term_coverage</code>	压低登录页与弱标题，突出多词覆盖和主题匹配

图 5.0.2: VSM + PageRank 排序证据

6 检索质量优化

大规模校内站点中存在三个影响演示体验的问题：一是部分 **WebPlus** 站点会生成大量标题相同、正文前缀几乎一致的导航页；二是网页正文开头常包含“首页、学院概

况、通知公告”等菜单文本，传统从第一次命中位置截取摘要时，结果页容易显示无关导航内容；三是登录跳转页、CAS 回调页、URL 标题页和编码文件名附件会进入索引，如果不处理，即使抓取 10 万甚至更多页面，也很难形成有效检索。

为此，排序后增加了结果级去重和主机多样性约束。系统使用 `title + body[:200]` 的 MD5 作为内容签名，相同签名只保留当前排序分最高的一条；随后在前 60 条候选窗口中限制同一 host 最多出现 3 条，超过部分并不删除，而是顺延到窗口之后。这样既保留完整召回，又避免某一个站点的列表页占满首页。

摘要生成也由“第一次命中”改为“命中密度最高窗口”。系统扫描全部查询词出现位置，以每个命中点为锚生成候选窗口，按“窗口内不同查询词数 $\times 3$ + 命中总次数”打分，并对文档前 120 字符的典型导航区扣分。最终摘要更容易展示正文中的有效信息，页面中仍用 `<mark>` 高亮查询词。新版结果页会直接展示 VSM、PageRank、主题匹配、精确匹配、多词覆盖、个性化和标题质量修正等排序信号，便于解释为什么某条结果靠前。

7 六项查询服务实现

7.1 站内查询

站内查询解析 `site:` 语法或页面中的站点输入框。例如：

1 就业 实习 双选会 `site:career.nankai.edu.cn`

Plain Text

后端将 `site:` 后的 host 作为过滤条件，只保留对应站点的结果，再对剩余 query 走 VSM 排序。

7.2 文档查询

文档查询解析 `filetype:` 语法或类型下拉框。例如：

1 国家级 实验教学示范中心 年度报告 `filetype:pdf`

Plain Text

系统根据 `doc_type` 字段过滤 PDF/DOCX/XLSX/HTML，并在结果页展示文件类型徽标和下载入口。

7.3 短语查询

短语查询支持英文双引号和中文引号。例如：

1 "南开 大学"

Plain Text

系统要求短语中的 term 在文本中保持邻接关系，因此 "南开 大学" 与 "南开 是一所综合性大学" 会被区别对待。

7.4 通配查询

通配查询支持 *、? 和正则语法。例如：

1 温*

2 计?

3 /信息.{0,2}/

Plain Text

通配符会被转换成正则表达式，并在标题、正文、锚文本和 URL 中匹配，命中标题的结果获得更高排序信号。

7.5 查询日志

用户登录后，每次搜索会写入 SQLite 的 query_log 表。首页展示最近查询历史，并提供清空历史按钮。点击搜索结果时，前端通过 /api/click 写入点击日志，为后续个性化排序提供依据。

7.6 网页快照

抓取时保存 HTML 原文至 snapshots/{md5(url)}.html.gz。搜索结果页提供“快照”按钮，后端读取本地快照，注入顶部横幅展示抓取时间和原始 URL，并重写相对链接为绝对链接。

下图选用 就业 实习 双选会 site:career.nankai.edu.cn 作为更显著的展示 case。首位结果直接命中“南开大学 2026 年就业实习双选会”，摘要展示时间、地点和正文说明，三个查询词全部高亮；site 过滤、快照入口、VSM + PageRank、多词覆盖和列表页降权信号都能在结果卡片中直接观察。

南开校内搜索

个性化演示 查询日志 登录 注册

就业 实习 双选会

站点: career.nankai.edu.cn 类型: 全部 后镜: 本地 VSM

教务 科研 招生 就业 图书馆

site: filetype: 短语 通配 正则

命中 2984 条 候选 3117 条 6374.1 ms 本地倒排召回 VSM + PageRank 重排 site:career.nankai.edu.cn

排序策略: 本地倒排召回 → VSM → PageRank → 多样性

当前查询: 就业 实习 双选会

结果质量: 弱标题/登录页自动降权, 单站点首屏降速

HTML 南开大学2026年就业实习双选会
https://career.nankai.edu.cn/Recruitment/content/type/1/id/365.html

命中摘要: ...**双选会** 南开大学2026年 **就业 实习 双选会** 时间: 2026-05-15 14:00 地点: 南开大学八里台校区 浏览量: 6538 尊敬的用人单位: 衷心感谢您对我校毕业生及毕业生 **就业** 工作的关爱与支持。为满足毕业生求职和用人单位招聘需要, 学生 **就业** 指导中心定于 2026 年 5 月 15 日 (星期五) 举办 “南开大学 2026 年 **就业 实习 双选会**”, 在此诚挚...

VSM PageRank 新鲜度 主题匹配 多词覆盖 site

快照 career.nankai.edu.cn 排序证据

HTML 南开大学举办2026年就业实习双选会
https://career.nankai.edu.cn/news/content/id/1975.html

命中摘要: ...新闻详细页 南开大学举办2026年 **就业 实习 双选会** 日期: 2026-05-18 人气: 156 为深入贯彻 **就业** 优先战略, 扎实推进2026、2027届毕业生高质量充分 **就业**, 精准搭建校企对接平台, 5月15日, 南开大学2026年 **就业 实习 双选会** 在八里台校区顺利举办。本次 **双选会** 由南开大学学生 **就业** 指导中心主办, 浙江省、南昌市企业组团参会, 同时汇聚南开校友企业及全国优秀用人...

VSM PageRank 新鲜度 主题匹配 多词覆盖 site

快照 career.nankai.edu.cn 排序证据

HTML 南开大学泰达学院 (校区) 2026年春季就业实习双选会
https://career.nankai.edu.cn/recruitment/content/type/1/id/357.html

相关推荐

HTML 南开大学学生就业指导中心 career.nankai.edu.cn

HTML 招聘信息|南开大学学生就业指导中心 career.nankai.edu.cn

HTML 招聘会信息|南开大学学生就业指导中心 career.nankai.edu.cn

HTML 招聘会信息|南开大学学生就业指导中心 career.nankai.edu.cn

HTML 文件下载|南开大学学生就业指导中心 career.nankai.edu.cn

继续筛选

移除 site

只看 PDF

南开新闻网

图 7.6.3: 就业双选会站内查询与摘要优化截图

南开校内搜索

个性化演示 查询日志 登录 注册

国家实验教学示范中心 年度报告

站点 cc.nankai.edu.cn 类型 pdf 后滴 本地 VSM

教务 科研 招生 就业 图书馆

site: filetype: 短语 通配 正则

命中 1863 条 候选 1929 条 15815.6 ms 本地倒排召回 VSM + PageRank 重排 filetype:pdf

排序策略 本地倒排召回 → VSM → PageRank → 多样性 当前查询 国家实验教学示范中心 年度报告 结果质量 弱标题/登录页自动降权, 单站点首屏限流

PDF 国家实验教学示范中心年度报告 (2019年1月1日)
https://cec.nankai.edu.cn/nb2019.pdf

命中摘要 ...06 通过验收年份 2012 国家实验教学示范中心年度报告 (2019年1月1日—2019年12月31日) 实验教学中心名称: 化学国家实验教学示范中心 (南开大学) 实验教学中心主任: 邱晓航 实验教学中心联系人/联系电话: 徐娜/13920273553 实验教学中心联系人电子邮箱: naxu@nankai.edu.cn 所在学校名称: 南开大学 所在学...

VSM PageRank 新鲜度 主题匹配 标题质量修正 文档检索 filetype

下载 cec.nankai.edu.cn 排序证据

PDF 国家实验教学示范中心年度报告 (2017年1月)
https://cec.nankai.edu.cn/nb2017.pdf

命中摘要 ...立项年份 2006 通过验收年份 国家实验教学示范中心年度报告 (2017年1月—2017年12月) 实验教学中心名称: 化学国家实验教学示范中心 (南开大学) 实验教学中心主任: 李一峻 实验教学中心联系人/联系电话: 徐娜/13920273553 实验教学中心联系人电子邮箱: naxu@nankai.edu.cn 所在学校名称: 南开大学...

VSM PageRank 新鲜度 主题匹配 标题质量修正 文档检索 filetype

下载 cec.nankai.edu.cn 排序证据

PDF 附件: 批准立项年份 2006 通过验收年份 国家实验教学示范中心年度报告 (2016年1月)
https://cec.nankai.edu.cn/nb2016.pdf

命中摘要 ...立项年份 2006 通过验收年份 国家实验教学示范中心年度报告 (2016年1月—2016年12月) 实验教学中心名称: 化学国家实验教学示范中心 (南开大学) 实验教学中心主任: 李一峻 实验教学中心联系人/联系电话: 徐娜/13920273553 实验教学中心联系人电子邮箱: naxu@nankai.edu.cn 所在学校名称: 南开大学 所在学校联系人/联系电话: ...

VSM PageRank 新鲜度 主题匹配 标题质量修正 文档检索 filetype

下载 cec.nankai.edu.cn 排序证据

PDF 过验收年份 2011 国家实验教学示范中心年度报告 (2019年1月1日)
https://pec.nankai.edu.cn/_upload/article/files/3b/4f/7ec0453046d6a27e0352e650225b/77a8f4d5-4d71-4022-b21e-a6f0aa24dbb9.pdf

命中摘要 ...年份 2006 过验收年份 2011 国家实验教学示范中心年度报告 (2019年1月1日—2019年12月31日) 实验教学中心名称: 基础物理国家实验教学示范中心 实验教学中心主任: 孔勇发 实验教学中心联系人/联系电话: 王 晓杰 / 15222039963 实验教学中心联系人电子邮箱: wxj@nankai.edu.cn 所在学校名称: 南开大学 所在学校联系人...

VSM PageRank 新鲜度 主题匹配 标题质量修正 文档检索 filetype

下载 pec.nankai.edu.cn 排序证据

PDF 国家实验教学示范中心年度报告 (2018年1月)
https://pec.nankai.edu.cn/_upload/article/files/3b/4f/7ec0453046d6a27e0352e650225b/77a8f4d5-4d71-4022-b21e-a6f0aa24dbb9.pdf

命中摘要 ...2006 通过验收年份 2011 国家实验教学示范中心年度报告 (2018年1月—2018年12月) 实验教学中心名称: 基础物理国家实验教学示范中心 实验教学中心主任: 孔勇发 实验教学中心联系人/联系电话: 孔勇发 / 13820193619 实验教学中心联系人电子邮箱: kongyif@nankai.edu.cn 所在学校名称: 南开大学 所在学...

VSM PageRank 新鲜度 主题匹配 标题质量修正 文档检索 filetype

下载 pec.nankai.edu.cn 排序证据

PDF 国家实验教学示范中心年度报告 (2020年1月1日)
https://pec.nankai.edu.cn/_upload/article/files/3b/4f/7ec0453046d6a27e0352e650225b/b4d76060-6ef3-417e-a455-11d4b295c538.pdf

相关推荐

PDF e69a74c4-1169-42f0-96a8-5ca2f8f98818
pec.nankai.edu.cn

PDF 71f8dbad-bf66-43ae-8f2f-3ab414a3a2d4
pec.nankai.edu.cn

PDF 3c198b6e-a977-4098-b23d-fdb0836aBada
pec.nankai.edu.cn

PDF nb2021
cec.nankai.edu.cn

PDF nb2020
cec.nankai.edu.cn

继续筛选

移除 filetype

只看 PDF

南开新闻网

个性化对比

图 7.6.4: PDF 文档查询与摘要优化截图




图 7.6.5: CNKI 站点检索与乱码修复截图

8 用户系统、个性化与推荐

系统提供注册、登录、退出功能。注册时用户选择角色（本科生、研究生、教师、校友、访客）和兴趣标签（新闻、教务、学术、招聘、文体、院系、图书馆、计算机）。排序阶段根据以下因素修正：

- 兴趣标签命中文档标签或标题正文时上提;

- 本科生和研究生更偏 HTML 教务通知；
- 教师更偏 PDF/DOCX/XLSX 学术与文档资源；
- 历史点击过的 URL 轻量上提。

个性化推荐包含两部分：输入框搜索联想来自标题和高频词；结果页相关推荐根据当前查询词、用户兴趣、角色偏好、资源类型和 PageRank 选取相关文档，并显示“兴趣命中、同主题、文档资源、站内权威”等推荐理由。演示页使用 **人工智能 学术 讲座** 等 case 对比访客、本科生和教师画像，可以看到同一查询下三类画像的 Top1、Top10 类型分布和相关推荐均出现可解释差异。

南开校内搜索

个性化排序演示

同一个查询先进入同一套 VSM + PageRank 候选池，再叠加角色、兴趣、资源类型和历史点击信号，页面直接展示排序变化和推荐理由。

人工智能 学术 讲座

对比

课程 就业 实习 双选会 图书馆 CNKI

人工智能 学术 讲座

访客

VSM + PageRank + 新鲜度

通用排序 质量权威 站点多样性

命中 2135 条 4639.4 ms Top10 HTML 10

Top10 文档 0

通用基础

HTML 通知 HTML 100% / 文档 0%

Top 结果

HTML

人工智能创作的创新扩散研究

...本书对人工智能创作的概念、内涵和外延进行了界定，对人工智能创作的路径、特征和与人类创作的差异性进行了分析，力求在对研究对象有清晰把握的基础上，依托罗杰斯的创新扩散理论，分析人工智能创作如何实现创新，以及如何在社会上扩散。...

VSM PageRank 新鲜度

libsk.nankai.edu.cn

HTML

南开校友总会人工智能校友分会成立-南开要闻-南开大学

...作为南开校友总会人工智能校友分会首任会长，周儒欣在致辞中回顾了校友分会的筹备历程，感谢卢桂堂教授对自己的深远影响，并阐述了“人工智能校友分会”、“卢桂堂人工智能发展基金”、“人工智能学科发展顾问委员会”三位一体、联动发力的建设思路。...

VSM PageRank 新鲜度

career.nankai.edu.cn

本科生 / 教务兴趣

提升教务、课程、就业和网页通知

教务 课程 HTML 通知

命中 2135 条 4339.4 ms Top10 HTML 10

Top10 文档 0

Top1 已因画像改变

HTML 通知 HTML 100% / 文档 0%

Top 结果

HTML

企业邀请函|南开大学人工智能学院2025年秋季就业实习双选会

...南开大学人工智能学院坚持——算法与系统“软硬结合”，方法与应用“两翼齐飞”的建设思路，在研究人工智能方法的同时，重点聚焦各类方法与智能机器人等系统的紧密结合，力争用人工智能方法提升机器人等系统的智能化水平，同时以智能系统的具体需求来推动人工智能方法的发展，在服务于国家和地方经济建设的同时，推动人工智能学科的发展。...

VSM PageRank 新鲜度

career.nankai.edu.cn

HTML

南开校友总会人工智能校友分会成立-南开要闻-南开大学

...作为南开校友总会人工智能校友分会首任会长，周儒欣在致辞中回顾了校友分会的筹备历程，感谢卢桂堂教授对自己的深远影响，并阐述了“人工智能校友分会”、“卢桂堂人工智能发展基金”、“人工智能学科发展顾问委员会”三位一体、联动发力的建设思路。...

VSM PageRank 新鲜度

news.nankai.edu.cn

教师 / 学术兴趣

提升学术、图书馆和可下载文档

学术 图书馆 文档资源

命中 1856 条 4660.1 ms Top10 HTML 9

Top10 文档 1

Top1 已因画像改变

HTML 通知 HTML 90% / 文档 10%

Top 结果

HTML

南开校友总会人工智能校友分会成立-南开要闻-南开大学

...作为南开校友总会人工智能校友分会首任会长，周儒欣在致辞中回顾了校友分会的筹备历程，感谢卢桂堂教授对自己的深远影响，并阐述了“人工智能校友分会”、“卢桂堂人工智能发展基金”、“人工智能学科发展顾问委员会”三位一体、联动发力的建设思路。...

VSM PageRank 新鲜度

news.nankai.edu.cn

HTML

企业邀请函|南开大学人工智能学院2025年秋季就业实习双选会

...南开大学人工智能学院坚持——算法与系统“软硬结合”，方法与应用“两翼齐飞”的建设思路，在研究人工智能方法的同时，重点聚焦各类方法与智能机器人等系统的紧密结合，力争用人工智能方

图 8.0.6: 个性化排序与推荐演示截图



图 8.0.7: 网页快照真实截图


9 Web 界面与 CLI

Web 界面以功能为主，包含首页、结果页、快照页、登录页、注册页和接口路由。主要路由如下：

路由	方法	说明
/	GET	搜索首页和查询历史
/search	GET	搜索结果页
/snapshot	GET	网页快照
/api/suggest	GET	搜索联想
/api/stats	GET	语料规模与后端状态
/personalization-demo	GET	访客、学生、教师三类画像排序对比
/api/click	POST	点击日志
/login, /register, /logout	GET/POST	用户系统

命令行入口由 `python -m nku_search.cli` 提供，`pixi` 中封装了常用任务：

```
1 pixi run init-demo
2 pixi run selfcheck
3 pixi run search -- "国家级 实验教学示范中心 年度报告 filetype:pdf"
```



```

4 pixi run serve
5 // 已有本机 ES 服务时，再执行下面的导入命令
6 pixi run build-es-index
7 .\.pixi\envs\default\python.exe .\scripts\crawl_to_100k.py

```

10 自检结果

项目提供 `selfcheck.py` 自动验收脚本，覆盖索引、六项查询、VSM、个性化和 Web 路由。当前自检输出如下：

1	[index] documents >= 2000	PASS 132296	Plain Text
2	[query] site	PASS	
3	[query] filetype	PASS	
4	[query] phrase	PASS	
5	[query] wildcard	PASS	
6	[query] regex	PASS	
7	[query] snapshot render	PASS	
8	[query] attachment file	PASS	
9	[ranking] VSM cosine	PASS cos=1.000	
10	[elastic] optional recall DSL	PASS	
11	[personalize] ranking/recommend	PASS	
12	[web] index	PASS	
13	[web] search	PASS	
14	[web] suggest	PASS	
15	[web] snapshot	PASS	
16	[web] download	PASS	
17	ALL PASS - ready to submit.		


```
===== SELFCHK =====
[index] documents >= 2000      PASS 132296
[index] title field exists     PASS
[index] anchor field exists    PASS
[index] pagerank computed      PASS
[query] site                   PASS
[query] filetype               PASS
[query] phrase                 PASS
[query] wildcard               PASS
[query] regex                  PASS
[query] snapshot render       PASS
[query] attachment file       PASS
[quality] top results readable PASS
[ranking] VSM cosine           PASS cos=1.000
[elastic] optional recall DSL  PASS
[personalize] ranking/recommend PASS
[web] index                   PASS
[web] search                   PASS
[web] suggest                  PASS
[web] snapshot                 PASS
[web] download                 PASS
===== SUMMARY =====
ALL PASS - ready to submit.
```

图 10.0.8: selfcheck 全部通过截图

11 不足与后续改进

第一，当前系统已经完成 132296 条真实南开文档抓取，并额外完成 32052 条高质量 HTML 定向补爬；最终提交时应保留抓取统计、自检输出和 Web 页面截图作为评分证据。第二，当前 ES 召回使用内置 analyzer 即可演示；后续若追求更好的中文召回质量，可以接入 IK 分词器、completion suggester 和查询缓存。第三，当前附件解析覆盖 PDF/DOC/DOCX/XLS/XLSX，旧版 Office 文档的文本抽取质量仍可通过 Apache Tika 或 LibreOffice 进一步增强。

总体而言，系统已按助教原文完成核心模块：礼貌抓取、多字段索引、VSM + PageRank 排序、六项查询服务、个性化查询、Web 界面和个性化推荐。