

南开校内 Web 搜索引擎

HW4 - Information Retrieval

面向南开校内资源的垂直搜索系统

Elasticsearch 召回 + 本地 VSM + PageRank + Flask



作业要求对齐

- 南开校内资源抓取，目标规模不少于 10 万页
- 多字段文本索引：标题、URL、正文、锚文本、附件文本
- 基于向量空间模型，结合链接分析排序
- 六项查询：站内、文档、短语、通配、日志、快照
- 登录用户个性化排序和个性化推荐


总体架构

- 检索层：Elasticsearch 召回候选，或本地倒排兜底
- 排序层：VSM + PageRank + 新鲜度 + 个性化
- ES 不直接决定最终排序，避免默认 BM25 取代作业要求的 VSM

阶段	模块	产物
抓取	crawler.py	HTML、附件、快照
索引	indexer.py + ES	本地索引、ES 索引
排序	search.py	VSM + PageRank
Web	web.py	查询、日志、快照、推荐

抓取与快照

- *.nankai.edu.cn 白名单
- 遵守 robots.txt，按主机限速并支持断点续爬
- HTML 原文 gzip 保存为网页快照
- 已抓取 132296 条文档，外链 0 条，覆盖 356 个南开主机
- 本轮定向新增 32052 条高质量 HTML 页面，frontier 扩展到 384801 条
- PDF/DOC/DOCX/XLS/XLSX 附件解析入索引



索引与 VSM 排序

- 分词: jieba 搜索模式 + 南开自定义词典
- ES 与本地索引共用 title、anchor、body、attachment
- ES 负责候选召回, 未连接时自动本地兜底
- 主排序: TF-IDF 余弦相似度
- 链接分析: PageRank 作为排序增益
- 主题意图 + 多词覆盖 + 标题质量修正
- 结果去重 + 主机多样性, 避免列表页霸屏

$$\text{score} = \left(\sum_f w_f \cdot \text{sim}_{f(q, d_f)} \right) \cdot (1 + 0.5 \log(1 + \text{PR}(d))) + 0.1 \cdot \text{fresh}(d)$$

六项查询功能

功能	示例
站内查询	就业 实习 双选会 site:career.nankai.edu.cn
文档查询	国家级 实验教学示范中心 年度报告 filetype:pdf
站点查询	CNKI site:lib.nankai.edu.cn
通配查询	温*, 计?, /信息.{0,2}/
查询日志	登录后自动保存历史
网页快照	结果页点击 “快照”

文档查询效果

南开校内搜索

个性化演示 查询日志 登录 注册

国家实验教学示范中心 年度报告

cc.nankai.edu.cn

类型pdf 范围本馆 VSM

教师 科研 招生 就业 图书馆

site filetype 链接 匹配 正则

命中 1863 条 经过 1929 条 15815.6 ms 本地倒排索引 VSM + PageRank 重排 filetypepdf

检索策略本馆倒排索引 → VSM → PageRank → 多样性结果预览国家实验教学示范中心 年度报告 预览策略预览/预览页自动授权, 单站点直接预览

PDF 国家实验教学示范中心年度报告 (2019年 1月 1日)https://cc.nankai.edu.cn/hb2019.pdf

命中摘要...06 通过验收年份 2012 国家实验教学示范中心年度报告 (2019年 1月 1日——2019年 12月 31日) 实验教学中心名称: 化学国家实验教学示范中心 (南开大学) 实验教学中心主任: 徐德福 实验教学中心联系人/联系电话: 徐德福/13920273553 实验教学中心联系人电子邮箱: naxu@nankai.edu.cn 所在学校名称: 南开大学 所在学...VSM PageRank 新检索 主题匹配 标量匹配修正 文档检索 filetype下载 cc.nankai.edu.cn 检索证明

PDF 国家实验教学示范中心年度报告 (2017年 1月)http://cc.nankai.edu.cn/hb2017.pdf

命中摘要...立馆年份 2006 通过验收年份 国家实验教学示范中心年度报告 (2017年 1月——2017年 12月) 实验教学中心名称: 化学国家实验教学示范中心 (南开大学) 实验教学中心主任: 李一松 实验教学中心联系人/联系电话: 徐德福/13920273553 实验教学中心联系人电子邮箱: naxu@nankai.edu.cn 所在学校名称: 南开大学...VSM PageRank 新检索 主题匹配 标量匹配修正 文档检索 filetype下载 cc.nankai.edu.cn 检索证明

PDF 附件: 批准立项年份 2 006 通过验收年份 国家实验教学示范中心年度报告 (2016年 1月)http://cc.nankai.edu.cn/hb2016.pdf

命中摘要...立馆年份 2 006 通过验收年份 国家实验教学示范中心年度报告 (2016年 1月——2016年 12月) 实验教学中心名称: 化学实验教学中心 实验教学中心主任: 李一松 实验教学中心联系人/联系电话: 徐德福/13920273553 实验教学中心联系人电子邮箱: naxu@nankai.edu.cn 所在学校名称: 南开大学 所在学校联系人/联系电话: ...VSM PageRank 新检索 主题匹配 标量匹配修正 文档检索 filetype下载 cc.nankai.edu.cn 检索证明

PDF 过验收年份 2011 国家实验教学示范中心年度报告 (2019年1月1日)https://pec.nankai.edu.cn/_upload/article/files/7b/40/7ed0453046d6a27ed032650225b/57347d01-4d8f-47f5-b9d4-6eecd355d80.pdf

命中摘要...年份 2006 过验收年份 2011 国家实验教学示范中心年度报告 (2019年1月1日——2019年12月31日) 实验教学中心名称: 基础物理国家实验教学示范中心 实验教学中心主任: 孔恩发 实验教学中心联系人/联系电话: 王明杰 / 1522039963 实验教学中心联系人电子邮箱: wuj@nankai.edu.cn 所在学校名称: 南开大学 所在学校联系人...VSM PageRank 新检索 主题匹配 标量匹配修正 文档检索 filetype下载 pec.nankai.edu.cn 检索证明

PDF 国家实验教学示范中心年度报告 (2018年 1月)https://pec.nankai.edu.cn/_upload/article/files/7b/40/7ed0453046d6a27ed032650225b/77a84d5-4d71-4022-b21e-a90aa24dbb0.pdf

命中摘要...2006 通过验收年份 2011 国家实验教学示范中心年度报告 (2018年 1月——2018年 12月) 实验教学中心名称: 基础物理国家实验教学示范中心 实验教学中心主任: 孔恩发 实验教学中心联系人/联系电话: 孔恩发 / 13920193619 实验教学中心联系人电子邮箱: kongyf@nankai.edu.cn 所在学校名称: 南开大学 所在学校...VSM PageRank 新检索 主题匹配 标量匹配修正 文档检索 filetype下载 pec.nankai.edu.cn 检索证明

PDF 国家实验教学示范中心年度报告 (2020年1月1日)https://pec.nankai.edu.cn/_upload/article/files/7b/40/7ed0453046d6a27ed032650225b/b4d76060-6ef3-417a-4d55-1164b295c538.pdf

相关推荐

PDF e69a74c4-1169-42f0-96a8-5ca2f8f98818pec.nankai.edu.cn

PDF 71f8dbad-bf66-43ae-8f2f-3ab414a3a2d4pec.nankai.edu.cn

PDF 3c198b6e-a977-4098-b23d-fdb0836abadapec.nankai.edu.cn

PDF nb2021cc.nankai.edu.cn

PDF nb2020cc.nankai.edu.cn

继续筛选

删除 filetype

只看 PDF

展开全部网页

个性化对比

站内查询与摘要

南开校内搜索

个性化演示 查询日志 登录 注册

就业 实习 双选会

站点career.nankai.edu.cn 类型全部 后端本地 VSM

教务 科研 招生 就业 图书馆

site filetype: 短语 通配 正则

命中 2984 条 候选 3117 条 6374.1 ms 本地倒排召回 VSM + PageRank 重排 site:career.nankai.edu.cn

排序链路本地倒排召回 → VSM → PageRank → 多样性

当前查询就业 实习 双选会

结果质量弱标题/登录页自动降权, 单站点首屏限流

HTML 南开大学2026年就业实习双选会

https://career.nankai.edu.cn/Recruitment/content/type/1/id/365.html

命中摘要

就业 实习 双选会

...双选会 南开大学2026年就业 实习 双选会 时间: 2026-05-15 14:00 地点: 南开大学八里台校区 浏览量: 6538 尊敬的用人单位: 衷心感谢您对我校毕业生及毕业生就业工作的关爱与支持。为满足毕业生求职和用人单位招聘需要, 学生就业指导中心定于 2026 年 5 月 15 日(星期 五) 举办 “南开大学 2026 年就业 实习 双选会”, 在此诚挚...

VSM PageRank 新鲜度 主题匹配 多词覆盖 site

快照 career.nankai.edu.cn

排序证据

HTML 南开大学举办2026年就业实习双选会

https://career.nankai.edu.cn/news/content/id/1975.html

命中摘要

就业 实习 双选会

...新闻详细页 南开大学举办2026年就业 实习 双选会 日期: 2026-05-18 人气: 156 为深入贯彻就业优先战略, 扎实推进2026、2027届毕业生高质量充分就业, 精准搭建校企对接平台, 5月15日, 南开大学2026年就业 实习 双选会在八里台校区顺利举办。本次双选会由南开大学学生就业指导中心主办, 浙江省、南昌市企业组团参会, 同时汇聚南开校友企业及全国优质用人...

VSM PageRank 新鲜度 主题匹配 多词覆盖 site

快照 career.nankai.edu.cn

排序证据

HTML 南开大学泰达学院(校区)2026年春季就业实习双选会

https://career.nankai.edu.cn/recruitment/content/type/1/id/357.html

命中摘要

就业 实习 双选会

...

VSM PageRank 新鲜度 主题匹配 多词覆盖 site

快照 career.nankai.edu.cn

排序证据

相关推荐

HTML 南开大学学生就业指导中心

career.nankai.edu.cn

HTML 招聘信息|南开大学学生就业指导中心

career.nankai.edu.cn

HTML 招聘会信息|南开大学学生就业指导中心

career.nankai.edu.cn

HTML 文件下载|南开大学学生就业指导中心

career.nankai.edu.cn

继续筛选


移除 site

只看 PDF

南开新闻网

个性化与推荐

- 注册时选择角色和兴趣标签
- 本科生/研究生偏 HTML 教务通知
- 教师偏 PDF/DOCX/XLSX 学术文档
- 人工智能 学术 讲座 case 展示三类画像 Top1 差异
- 搜索联想来自标题和高频词
- 相关推荐显示兴趣命中、同主题、文档资源等推荐理由



结果质量优化

- 低质量页：CAS/登录/跳转、URL 标题、空正文页面自动降权
- 摘要显示：按命中句子选段，跳过导航、版权和列表噪声
- 文档查询：不可读 PDF 文件名优先回退到报告/通知类正文标题
- 编码修复：自动修复 UTF-8 被误读造成的 CNKI 等乱码结果
- 查询意图：就业、教务、招生、图书馆、科研等主题信号参与重排
- 内容签名：title + body[:200] 合并重复导航/列表页
- 前 60 条窗口内每个 host 最多 3 条，提升结果多样性
- 摘要选择命中密度最高窗口，避开正文开头导航菜单

Web 与 CLI 演示

- `pixi run selfcheck` 在 132296 条真实文档上自动验收
- `pixi run targeted-crawl -- --dry-run` 先检查定向增量 frontier
- `pixi run targeted-crawl -- --target-new 30000` 可在现有 frontier 上继续增量维护
- 本机已有 ES 服务时, `pixi run build-es-index` 写入 ES 索引
- `pixi run search -- "国家级 实验教学示范中心 年度报告 filetype:pdf"` 命令行搜索
- `pixi run serve` 启动 Flask Web

自检结果

```
===== SELF-CHECK =====
[index] documents >= 2000      PASS 132296
[index] title field exists     PASS
[index] anchor field exists    PASS
[index] pagerank computed      PASS
[query] site                   PASS
[query] filetype               PASS
[query] phrase                 PASS
[query] wildcard               PASS
[query] regex                  PASS
[query] snapshot render       PASS
[query] attachment file       PASS
[quality] top results readable PASS
[ranking] VSM cosine           PASS cos=1.000
[elastic] optional recall DSL  PASS
[personalize] ranking/recommend PASS
[web] index                    PASS
[web] search                   PASS
[web] suggest                  PASS
[web] snapshot                 PASS
[web] download                 PASS
===== SUMMARY =====
ALL PASS - ready to submit.
```

132296 条文档上已覆盖：索引、六项查询、VSM、个性化、Web 路由。

提交材料与验证

- 报告、PPT、讲解稿和抓取证据已放入 说明文档/
- 保留 132296 条抓取统计、主机分布和 selfcheck 输出作为证据
- 代码压缩包排除超大语料，报告与视频证明真实规模
- 演示视频按 15 分钟以内脚本录制
- 最终提交前用真实学号姓名重新运行 `pixi run package`